

# Métodos Numéricos para Autovalores

# Principais Teoremas

## Teorema dos Círculos de Gershgorin

- Autovalores estão dentro dos discos de Gershgorin:

$$D(a_{ii}, R_i) \quad \text{com} \quad R_i = \sum_{j \neq i} |a_{ij}|.$$

- Maneira rápida de estimar onde os autovalores podem estar.

### Significado:

O teorema diz que cada autovalor está em pelo menos um dos discos centrados em cada entrada da diagonal com raio igual à soma dos valores absolutos na mesma linha.

### Relevância:

É uma maneira rápida de limitar ou adivinhar onde os autovalores podem estar, para que você não entre em uma busca desenfreada por eles.

## Demonstração

Considere:

1.  $A \in \mathbb{C}^{n \times n}$ ,
2.  $\lambda$  um autovalor de  $A$ ,
3.  $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$  um autovetor associado, com  $\mathbf{x} \neq \mathbf{0}$

Selecione um índice  $k$  tal que:

$$|x_k| = \max_{1 \leq i \leq n} |x_i|$$

Assim, temos:

$$|x_j| \leq |x_k| \quad \text{para todo } j = 1, 2, \dots, n.$$

## Aplicação na Equação dos Autovalores

Pela definição de autovalor, temos  $A\mathbf{x} = \lambda\mathbf{x}$ .

Para a  $k$ -ésima linha, a equação se torna:

$$\lambda x_k = a_{kk}x_k + \sum_{j \neq k} a_{kj}x_j.$$

Ou de forma equivalente:

$$(\lambda - a_{kk})x_k = \sum_{j \neq k} a_{kj}x_j.$$

Dividindo ambos os lados por  $x_k$  (lembrando que  $x_k \neq 0$ ):

$$\lambda - a_{kk} = \sum_{j \neq k} a_{kj} \frac{x_j}{x_k}.$$

## Aplicando a Desigualdade Triangular

Tomando o valor absoluto em ambos os lados:

$$|\lambda - a_{kk}| = \left| \sum_{j \neq k} a_{kj} \frac{x_j}{x_k} \right|$$

Usando a desigualdade triangular:

$$|\lambda - a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \left| \frac{x_j}{x_k} \right|.$$

Como  $|x_j/x_k| \leq 1$  para todo  $j$ :

$$|\lambda - a_{kk}| \leq \sum_{j \neq k} |a_{kj}| = R_k.$$

## Decomposição de Schur

- Toda matriz quadrada  $A$  pode ser transformada unitariamente:

$$A = QUQ^*$$

com  $U$  triangular superior.

- Os autovalores de  $A$  estão na diagonal de  $U$ .

### Significado:

Qualquer matriz pode ser "quase" diagonalizada. Em vez de diagonal, você obtém uma forma triangular superior com os mesmos autovalores na diagonal.

### Relevância:

É a base de muitos algoritmos de autovalores (como o método QR) que dependem da redução de uma matriz a algo mais simples, mas preservando os autovalores.

## Demonstração

### 1. Existência de um autovalor:

Seja  $A \in \mathbb{C}^{n \times n}$ . Pelo teorema da existência de autovalores, existe  $\lambda \in \mathbb{C}$  e um autovetor não nulo  $v$ . Normalizando, podemos assumir que  $\|v\| = 1$ .

### 2. Construção de uma base ortonormal:

Complete  $v$  para uma base ortonormal de  $\mathbb{C}^n$ . Seja  $Q_1$  a matriz unitária formada por essa base, onde a primeira coluna é  $v$ .

### 3. Transformação unitária:

Considere a transformação:

$$Q_1^* A Q_1 = \begin{bmatrix} \lambda & w^* \\ 0 & A_1 \end{bmatrix},$$

onde  $w \in \mathbb{C}^{n-1}$  e  $A_1 \in \mathbb{C}^{(n-1) \times (n-1)}$ .



#### 4. Aplicação de indução:

Pelo princípio da indução, existe uma matriz unitária  $Q_2 \in \mathbb{C}^{(n-1) \times (n-1)}$  que triangulariza  $A_1$ , isto é,

$$Q_2^* A_1 Q_2 = U_1,$$

onde  $U_1$  é triangular superior.

#### 5. Construção final:

Defina

$$Q = Q_1 \begin{bmatrix} 1 & 0 \\ 0 & Q_2 \end{bmatrix}, \quad \text{e} \quad U = \begin{bmatrix} \lambda & * \\ 0 & U_1 \end{bmatrix}.$$

Assim,  $Q$  é unitária com  $U$  triangular superior e seus elementos diagonais sendo os autovalores de  $A$ .

## Teorema Espectral

- Toda matriz  $A$  real e simétrica (ou Hermitiana) pode ser fatorada em

$$A = Q\Lambda Q^t,$$

- $\Lambda$  é diagonal e formada pelos autovalores de  $A$ .
- $Q$  é ortogonal, ou seja,  $QQ^t = I$ .

### Relevância:

Matrizes reais simétricas aparecem frequentemente (como matrizes de covariância em PCA). Saber que os autovalores são todos reais e os autovetores são ortonormais torna as coisas mais estáveis e fáceis de calcular.

## Demonstração

- O Teorema Espectral é um corolário da decomposição de Schur, pois  $A$  simétrica implica  $A = QUQ^* = QU^*Q^* = A^*$ . Portanto,  $U$  é triangular superior e Hermitiana, ou seja,  $U$  é real a diagonal ( $\Lambda$ ).
- Mais ainda, se  $v \in \mathbb{C}^n$  e  $\lambda \in \mathbb{R}$  formam um autopar de  $A$  (real e simétrica), então  $\lambda \bar{v} = \overline{\lambda v} = \overline{Av} = \overline{A\bar{v}} = A\bar{v}$ . Portanto,  $\bar{v}$  e  $u = v + \bar{v} \in \mathbb{R}^n$  serão autovetores de  $A$ . Logo, a partir da matriz unitária  $Q$ , podemos formar uma matriz real ortogonal de autovetores de  $A$ .

# Principais Algoritmos

# Método da Potência

## O Básico

- **Processo:** Repetidamente faça  $v_{k+1} = Av_k / \|Av_k\|$ .
- **Resultado:** Converge para o autovetor com o maior autovalor em magnitude.
- **Advertência:** Não funciona se seu vetor inicial for ortogonal ao autovetor principal, mas isto é improvável.

## Quando Usar

- Matrizes enormes e esparsas.
- Precisa apenas do autovalor dominante.

## Justificativa:

Seja  $v_0 = \sum_{j=1}^n c_j v_j$ , onde  $v_j$  são os autovetores de  $A$  com  $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ . Então:

$$A^k v_0 = \lambda_1^k \left( c_1 v_1 + \sum_{j=2}^n c_j \left( \frac{\lambda_j}{\lambda_1} \right)^k v_j \right).$$

Para  $k \rightarrow \infty$ , os termos com  $j \geq 2$  decaem, de modo que a normalização de  $A^k v_0$  aproxima  $v_1$ .

## Autovalores de $A^{-1}$

Se  $A$  é uma matriz invertível e  $v$  é um autovetor com autovalor  $\lambda$ , então

$$Av = \lambda v.$$

Multiplicando ambos os lados por  $A^{-1}$ , temos

$$v = \lambda A^{-1}v \quad \implies \quad A^{-1}v = \frac{1}{\lambda}v.$$

Ou seja, os autovalores de  $A^{-1}$  são os inversos dos autovalores de  $A$ .

## Deflação

Podemos remover a influência de um autopar já calculado da matriz para encontrar os autovalores subsequentes.

***Para matrizes simétricas:***

Dado um autopar  $(\lambda_1, v_1)$  com  $\|v_1\| = 1$ , defina a matriz deflacionada

$$A_1 = A - \lambda_1 v_1 v_1^T.$$

1. O autovalor  $\lambda_1$  é eliminado (ou reduzido a zero) em  $A_1$ .
2. Ao aplicarmos o Método da Potência a  $A_1$ , obtemos o próximo autovalor dominante da matriz original.
3. Repita o processo para calcular mais autopares:

$$A_2 = A_1 - \lambda_2 v_2 v_2^T = A - \lambda_1 v_1 v_1^T - \lambda_2 v_2 v_2^T.$$



## Deslocamento (Shift)

Podemos calcular um autovalor de  $A$  que não seja o dominante, modificando o espectro (distribuição dos autovalores).

### Justificativa

**Ideia:** Para um dado deslocamento escalar  $\sigma$ , forme a matriz deslocada

$$B = A - \sigma I.$$

Resolva

$$(A - \sigma I)^{-1} x_{k+1} = x_k,$$

O autovalor mais próximo de  $\sigma$  será o autovalor dominante de  $(A - \sigma I)^{-1}$ .

Após a convergência, recupere o autovalor de  $A$  através de

$$\lambda \approx \sigma + \frac{1}{\mu},$$

onde  $\mu$  é o autovalor dominante de  $(A - \sigma I)^{-1}$ .

# Algoritmo QR

## A Ideia

1. Fatore  $A_k = Q_k R_k$ .
2. Forme  $A_{k+1} = R_k Q_k$ .
3. Repita até que  $A_k$  seja triangular superior (autovalores na diagonal).

## Relevância

- Padrão ouro para matrizes densas.
- Detalhe de implementação: "Shifts" aceleram a convergência.

## Justificativa

A cada iteração, temos

$$A_{k+1} = R_k Q_k = Q_k^* A_k Q_k,$$

o que indica uma similaridade:

$$A_{k+1} \sim A_k$$

Se  $A$  for diagonalizável, o processo converge para uma matriz triangular  $U$  com os autovalores de  $A$  na diagonal.

**Caso:**  $2 \times 2$

Suponha

$$A = \begin{pmatrix} \lambda_1 & \epsilon \\ \delta & \lambda_2 \end{pmatrix},$$

com  $|\lambda_1| > |\lambda_2|$  e  $\epsilon, \delta$  pequenos.  
Desejamos rastrear a entrada subdiagonal  $\delta$ .

### Passo 1. Fatoração QR via uma Rotação de Givens:

Defina  $r = \sqrt{\lambda_1^2 + \delta^2}$ ,  $\cos \theta = \frac{\lambda_1}{r}$ ,  $\sin \theta = \frac{\delta}{r}$ , e faça

$$Q = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}.$$

Então, a fatoração é

$$A = QR \quad \text{com} \quad R = Q^T A.$$

Um breve cálculo resulta em:

- $r_{11} = \cos \theta \lambda_1 + \sin \theta \delta = r$ ,
- $r_{21} = -\sin \theta \lambda_1 + \cos \theta \delta = 0$  (por construção),
- $r_{22} = -\sin \theta \epsilon + \cos \theta \lambda_2$ .

## Passo 2. Forme a Próxima Iteração:

A próxima iteração é definida como  $A' = RQ$ .

Multiplicando, a entrada  $(2, 1)$  de  $A'$  é  $\delta' = r_{22} \sin \theta$ .

## Passo 3. Aproximação:

Assumindo que  $\epsilon$  é pequeno, aproxime

$$r_{22} \approx \cos \theta \lambda_2.$$

Assim,

$$\delta' \approx \cos \theta \lambda_2 \sin \theta.$$

Usando

$$\sin \theta = \frac{\delta}{r} \quad \text{e} \quad \cos \theta = \frac{\lambda_1}{r},$$

e notando que para  $\delta$  pequeno,  $r \approx \lambda_1$ , obtemos  $\delta' \approx \lambda_2 \frac{\delta}{\lambda_1}$ .

Tomando valores absolutos, concluímos que

$$|c'| = |\delta'| \approx |c| \left| \frac{\lambda_2}{\lambda_1} \right|.$$

Como  $|\lambda_1| > |\lambda_2|$ , temos uma contração do termo  $c = A_{2,1}$  localizado abaixo da diagonal.

# Método de Jacobi (para simétricas)

## Esboço

- Rotacione pares de eixos para zerar as entradas fora da diagonal.
- Converge para uma matriz diagonal com autovalores na diagonal.
- Redução da "energia" off-diagonal.

## Considerações

- Fácil de entender para ensino.
- Lento em problemas de grande escala, mas conceitualmente simples.

## Justificativa

- **Transformação de Similaridade:**

- Cada rotação  $G(i, j, \theta)$  satisfaz

$$A' = G(i, j, \theta)^T A G(i, j, \theta)$$

- Autovalores permanecem inalterados.

- **Redução Off-diagonal:**

- A rotação elimina (ou diminui) o elemento  $a_{ij}$ .
- Iterações sucessivas convergem para uma matriz quase diagonal.

## Matrizes de Rotação $G(i, j, \theta)$

### Construção:

Uma forma concisa de escrever a matriz de rotação  $G(i, j, \theta)$  é

$$G(i, j, \theta) = I_n + (\cos \theta - 1)(e_i e_i^T + e_j e_j^T) - \sin \theta (e_i e_j^T - e_j e_i^T),$$

onde  $I_n$  é a matriz identidade e  $e_i$  (ou  $e_j$ ) é o  $i$ -ésimo vetor canônico.

Essa notação garante que:

- Para  $k \neq i, j$ , a entrada  $G_{kk} = 1$ ;
- $G_{ii} = G_{jj} = 1 + (\cos \theta - 1) = \cos \theta$ ;
- $G_{ij} = -\sin \theta$  e  $G_{ji} = \sin \theta$ .

$G$  realiza uma rotação no plano das direções  $e_i$  e  $e_j$  e anula o elemento  $a_{ij}$  de  $A$  por meio de transformações de similaridade.



## Diferenças Entre $A$ e $A'$

- **(Alterados)** Bloco formado por linhas/colunas  $i$  e  $j$ :
  - $A'_{ii} = c^2 A_{ii} - 2sc A_{ij} + s^2 A_{jj}$
  - $A'_{jj} = s^2 A_{ii} + 2sc A_{ij} + c^2 A_{jj}$
  - $A'_{ij} = A'_{ji} = (c^2 - s^2)A_{ij} + sc(A_{ii} - A_{jj})$  (será anulado)
- **Inalterados:** Elementos com índices fora do conjunto  $\{i, j\}$ .
- **Nas linhas/colunas  $i$  e  $j$  com outros índices  $k$ :**
  - $A'_{ik} = c A_{ik} - s A_{jk}$
  - $A'_{jk} = s A_{ik} + c A_{jk}$
  - Portanto,  $(A'_{ik})^2 + (A'_{jk})^2 = A_{ik}^2 + A_{jk}^2$  ("energia" preservada)

## Preenchimento (Fill-in)

- **O que ocorre:**
  - Elementos inicialmente nulos em linhas/colunas  $i$  ou  $j$  podem se tornar não-nulos.
  - Isso ocorre devido às combinações lineares durante a rotação.
- **Impacto:**
  - O "fill-in" local não impede a convergência, pois a norma off-diagonal é reduzida.
  - No entanto, é inviável aplicá-lo em matrizes esparsas de grande escala.

## Garantia de Convergência

- **Mesmo com preenchimento:**
  - Cada rotação anula ou diminui significativamente o elemento  $A_{ij}$ .
  - A soma dos quadrados dos elementos fora da diagonal (norma off-diagonal) decai a cada iteração.
- **Resultado:**
  - A matriz converge para uma forma diagonal cujos elementos diagonais são os autovalores de  $A$ .

# Iteração do Quociente de Rayleigh

- Combina a iteração inversa com *shift* baseado no **Quociente de Rayleigh**

$$\rho(x) = \frac{x^T A x}{x^T x}$$

- O autopar é atualizado por iteração
- Convergência cúbica

```
def rqi(A, x0, iterations=10):  
    x = x0  
    I = np.eye(A.shape[0])  
    row = 0  
    for _ in range(iterations):  
        row_old = row  
        rho = x.T @ A @ x / (x.T @ x)  
        if np.abs(row - row_old) < epsilon:  
            break  
        x = solve(A - rho * I, x)  
        x = x / norm(x)  
  
    return row, x
```

## Justificativa

Em cada iteração, o RQI calcula o **Quociente de Rayleigh**

$$\rho(x) = \frac{x^T A x}{x^T x}$$

usando o vetor  $x$  da iteração anterior.

O valor  $\rho(x)$  serve como um **shift** dinâmico, ajustado a cada passo para se aproximar do autovalor desejado.

O RQI utiliza a **iteração inversa** com este shift dinâmico para encontrar o próximo vetor  $x_{k+1}$  resolvendo

$$(A - \rho(x_k)I)x_{k+1} = x_k.$$

A iteração inversa é equivalente ao método da potência aplicado à matriz **inversa deslocada**  $(A - \rho(x_k)I)^{-1}$ .

Se  $\lambda_i$  são os autovalores de  $A$ , então os autovalores de  $(A - \rho(x_k)I)^{-1}$  são

$$\mu_i = \frac{1}{\lambda_i - \rho(x_k)}$$

Finalmente, quando  $\rho(x_k)$  se aproxima de um autovalor  $\lambda_j$  de  $A$ , o autovalor  $\mu_j$  de  $(A - \rho(x_k)I)^{-1}$  torna-se **dominante em magnitude**, pois o denominador  $|\lambda_j - \rho(x_k)|$  fica cada vez menor.

Resumindo, o RQI acelera drasticamente a convergência ao refinar o shift dinâmico na iteração inversa.

# Método de Lanczos (para simétricas grandes)

## Destaques

- Constrói um subespaço de Krylov:  $\mathcal{K}_m(A, v) = \{v, Av, A^2v, \dots, A^{m-1}v\}$ .
- Produz uma matriz tridiagonal cujos autovalores se aproximam dos de  $A$ .

## Caso de uso

- Eficiente para matrizes esparsas e grandes.
- Geralmente usado para obter apenas os  $k$  autovalores principais.

# Método de Arnoldi (não simétricas)

## O que é?

- Generaliza Lanczos para matrizes não simétricas (ou não Hermitianas).
- Constrói uma matriz de Hessenberg superior que se aproxima dos autovalores (valores de Ritz).

## Caso de uso

- Problemas grandes, esparsos e não simétricos (como matrizes de adjacência de grafos direcionados).