

Métodos Numéricos para Autovalores

Principais Teoremas

Teorema dos Círculos de Gershgorin

- Autovalores estão dentro dos discos de Gershgorin:

$$D(a_{ii}, R_i) \quad \text{com} \quad R_i = \sum_{j \neq i} |a_{ij}|.$$

- Maneira rápida de estimar onde os autovalores podem estar.

Significado:

O teorema diz que cada autovalor está em pelo menos um dos discos centrados em cada entrada da diagonal com raio igual à soma dos valores absolutos na mesma linha.

Relevância:

É uma maneira rápida de limitar ou adivinhar onde os autovalores podem estar, para que você não entre em uma busca desenfreada por eles.

Demonstração

Considere:

1. $A \in \mathbb{C}^{n \times n}$,
2. λ um autovalor de A ,
3. $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ um autovetor associado, com $\mathbf{x} \neq \mathbf{0}$

Selecione um índice k tal que:

$$|x_k| = \max_{1 \leq i \leq n} |x_i|$$

Assim, temos:

$$|x_j| \leq |x_k| \quad \text{para todo } j = 1, 2, \dots, n.$$

Aplicação na Equação dos Autovalores

Pela definição de autovalor, temos $A\mathbf{x} = \lambda\mathbf{x}$.

Para a k -ésima linha, a equação se torna:

$$\lambda x_k = a_{kk}x_k + \sum_{j \neq k} a_{kj}x_j.$$

Ou de forma equivalente:

$$(\lambda - a_{kk})x_k = \sum_{j \neq k} a_{kj}x_j.$$

Dividindo ambos os lados por x_k (lembrando que $x_k \neq 0$):

$$\lambda - a_{kk} = \sum_{j \neq k} a_{kj} \frac{x_j}{x_k}.$$

Aplicando a Desigualdade Triangular

Tomando o valor absoluto em ambos os lados:

$$|\lambda - a_{kk}| = \left| \sum_{j \neq k} a_{kj} \frac{x_j}{x_k} \right|$$

Usando a desigualdade triangular:

$$|\lambda - a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \left| \frac{x_j}{x_k} \right|.$$

Como $|x_j/x_k| \leq 1$ para todo j :

$$|\lambda - a_{kk}| \leq \sum_{j \neq k} |a_{kj}| = R_k.$$

Decomposição de Schur

- Toda matriz quadrada A pode ser transformada unitariamente:

$$A = QUQ^*$$

com U triangular superior.

- Os autovalores de A estão na diagonal de U .

Significado:

Qualquer matriz pode ser "quase" diagonalizada. Em vez de diagonal, você obtém uma forma triangular superior com os mesmos autovalores na diagonal.

Relevância:

É a base de muitos algoritmos de autovalores (como o método QR) que dependem da redução de uma matriz a algo mais simples, mas preservando os autovalores.

Demonstração

1. Existência de um autovalor:

Seja $A \in \mathbb{C}^{n \times n}$. Pelo teorema da existência de autovalores, existe $\lambda \in \mathbb{C}$ e um autovetor não nulo v . Normalizando, podemos assumir que $\|v\| = 1$.

2. Construção de uma base ortonormal:

Complete v para uma base ortonormal de \mathbb{C}^n . Seja Q_1 a matriz unitária formada por essa base, onde a primeira coluna é v .

3. Transformação unitária:

Considere a transformação:

$$Q_1^* A Q_1 = \begin{bmatrix} \lambda & w^* \\ 0 & A_1 \end{bmatrix},$$

onde $w \in \mathbb{C}^{n-1}$ e $A_1 \in \mathbb{C}^{(n-1) \times (n-1)}$.

4. Aplicação de indução:

Pelo princípio da indução, existe uma matriz unitária $Q_2 \in \mathbb{C}^{(n-1) \times (n-1)}$ que triangulariza A_1 , isto é,

$$Q_2^* A_1 Q_2 = U_1,$$

onde U_1 é triangular superior.

5. Construção final:

Defina

$$Q = Q_1 \begin{bmatrix} 1 & 0 \\ 0 & Q_2 \end{bmatrix}, \quad \text{e} \quad U = \begin{bmatrix} \lambda & * \\ 0 & U_1 \end{bmatrix}.$$

Assim, Q é unitária com U triangular superior e seus elementos diagonais sendo os autovalores de A .

Teorema Espectral

- Toda matriz A real e simétrica (ou Hermitiana) pode ser fatorada em

$$A = Q\Lambda Q^t,$$

- Λ é diagonal e formada pelos autovalores de A .
- Q é ortogonal, ou seja, $QQ^t = I$.

Relevância:

Matrizes reais simétricas aparecem frequentemente (como matrizes de covariância em PCA). Saber que os autovalores são todos reais e os autovetores são ortonormais torna as coisas mais estáveis e fáceis de calcular.

Demonstração

- O Teorema Espectral é um corolário da decomposição de Schur, pois A simétrica implica $A = QUQ^* = QU^*Q^* = A^*$. Portanto, U é triangular superior e Hermitiana, ou seja, U é real a diagonal (Λ).
- Mais ainda, se $v \in \mathbb{C}^n$ e $\lambda \in \mathbb{R}$ formam um autopar de A (real e simétrica), então $\lambda \bar{v} = \overline{\lambda v} = \overline{Av} = \overline{A\bar{v}} = A\bar{v}$. Portanto, \bar{v} e $u = v + \bar{v} \in \mathbb{R}^n$ serão autovetores de A . Logo, a partir da matriz unitária Q , podemos formar uma matriz real ortogonal de autovetores de A .

Principais Algoritmos

Método da Potência

O Básico

- **Processo:** Repetidamente faça $v_{k+1} = Av_k / \|Av_k\|$.
- **Resultado:** Converge para o autovetor com o maior autovalor em magnitude.
- **Advertência:** Não funciona se seu vetor inicial for ortogonal ao autovetor principal, mas isto é improvável.

Quando Usar

- Matrizes enormes e esparsas.
- Precisa apenas do autovalor dominante.

Justificativa:

Seja $v_0 = \sum_{j=1}^n c_j v_j$, onde v_j são os autovetores de A com $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$. Então:

$$A^k v_0 = \lambda_1^k \left(c_1 v_1 + \sum_{j=2}^n c_j \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \right).$$

Para $k \rightarrow \infty$, os termos com $j \geq 2$ decaem, de modo que a normalização de $A^k v_0$ aproxima v_1 .

Autovalores de A^{-1}

Se A é uma matriz invertível e v é um autovetor com autovalor λ , então

$$Av = \lambda v.$$

Multiplicando ambos os lados por A^{-1} , temos

$$v = \lambda A^{-1}v \quad \implies \quad A^{-1}v = \frac{1}{\lambda}v.$$

Ou seja, os autovalores de A^{-1} são os inversos dos autovalores de A .

Deflação

Podemos remover a influência de um autopar já calculado da matriz para encontrar os autovalores subsequentes.

Para matrizes simétricas:

Dado um autopar (λ_1, v_1) com $\|v_1\| = 1$, defina a matriz deflacionada

$$A_1 = A - \lambda_1 v_1 v_1^T.$$

1. O autovalor λ_1 é eliminado (ou reduzido a zero) em A_1 .
2. Ao aplicarmos o Método da Potência a A_1 , obtemos o próximo autovalor dominante da matriz original.
3. Repita o processo para calcular mais autopares:

$$A_2 = A_1 - \lambda_2 v_2 v_2^T = A - \lambda_1 v_1 v_1^T - \lambda_2 v_2 v_2^T.$$

Deslocamento (Shift)

Podemos calcular um autovalor de A que não seja o dominante, modificando o espectro (distribuição dos autovalores).

Justificativa

Ideia: Para um dado deslocamento escalar σ , forme a matriz deslocada

$$B = A - \sigma I.$$

Resolva

$$(A - \sigma I)^{-1} x_{k+1} = x_k,$$

O autovalor mais próximo de σ será o autovalor dominante de $(A - \sigma I)^{-1}$.

Após a convergência, recupere o autovalor de A através de

$$\lambda \approx \sigma + \frac{1}{\mu},$$

onde μ é o autovalor dominante de $(A - \sigma I)^{-1}$.

Algoritmo QR

A Ideia

1. Fatore $A_k = Q_k R_k$.
2. Forme $A_{k+1} = R_k Q_k$.
3. Repita até que A_k seja triangular superior (autovalores na diagonal).

Relevância

- Padrão ouro para matrizes densas.
- Detalhe de implementação: "Shifts" aceleram a convergência.

Justificativa

A cada iteração, temos

$$A_{k+1} = R_k Q_k = Q_k^* A_k Q_k,$$

o que indica uma similaridade:

$$A_{k+1} \sim A_k$$

Se A for diagonalizável, o processo converge para uma matriz triangular U com os autovalores de A na diagonal.

Caso: 2×2

Suponha

$$A = \begin{pmatrix} \lambda_1 & \epsilon \\ \delta & \lambda_2 \end{pmatrix},$$

com $|\lambda_1| > |\lambda_2|$ e ϵ, δ pequenos.
Desejamos rastrear a entrada subdiagonal δ .

Passo 1. Fatoração QR via uma Rotação de Givens:

Defina $r = \sqrt{\lambda_1^2 + \delta^2}$, $\cos \theta = \frac{\lambda_1}{r}$, $\sin \theta = \frac{\delta}{r}$, e faça

$$Q = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}.$$

Então, a fatoração é

$$A = QR \quad \text{com} \quad R = Q^T A.$$

Um breve cálculo resulta em:

- $r_{11} = \cos \theta \lambda_1 + \sin \theta \delta = r$,
- $r_{21} = -\sin \theta \lambda_1 + \cos \theta \delta = 0$ (por construção),
- $r_{22} = -\sin \theta \epsilon + \cos \theta \lambda_2$.

Passo 2. Forme a Próxima Iteração:

A próxima iteração é definida como $A' = RQ$.

Multiplicando, a entrada $(2, 1)$ de A' é $\delta' = r_{22} \sin \theta$.

Passo 3. Aproximação:

Assumindo que ϵ é pequeno, aproxime

$$r_{22} \approx \cos \theta \lambda_2.$$

Assim,

$$\delta' \approx \cos \theta \lambda_2 \sin \theta.$$

Usando

$$\sin \theta = \frac{\delta}{r} \quad \text{e} \quad \cos \theta = \frac{\lambda_1}{r},$$

e notando que para δ pequeno, $r \approx \lambda_1$, obtemos $\delta' \approx \lambda_2 \frac{\delta}{\lambda_1}$.

Tomando valores absolutos, concluímos que

$$|c'| = |\delta'| \approx |c| \left| \frac{\lambda_2}{\lambda_1} \right|.$$

Como $|\lambda_1| > |\lambda_2|$, temos uma contração do termo $c = A_{2,1}$ localizado abaixo da diagonal.

Método de Jacobi (para simétricas)

Esboço

- Rotacione pares de eixos para zerar as entradas fora da diagonal.
- Converge para uma matriz diagonal com autovalores na diagonal.
- Redução da "energia" off-diagonal.

Considerações

- Fácil de entender para ensino.
- Lento em problemas de grande escala, mas conceitualmente simples.

Justificativa

- **Transformação de Similaridade:**

- Cada rotação $G(i, j, \theta)$ satisfaz

$$A' = G(i, j, \theta)^T A G(i, j, \theta)$$

- Autovalores permanecem inalterados.

- **Redução Off-diagonal:**

- A rotação elimina (ou diminui) o elemento a_{ij} .
- Iterações sucessivas convergem para uma matriz quase diagonal.

Matrizes de Rotação $G(i, j, \theta)$

- **Construção:**

- Partem da matriz identidade I_n .
- Modificações:
 - $G_{ii} = \cos \theta$
 - $G_{ij} = -\sin \theta$
 - $G_{ji} = \sin \theta$
 - $G_{jj} = \cos \theta$
- Outras entradas: inalteradas.

- **Objetivo:**

- Anular o elemento a_{ij} de A por meio de transformações de similaridade.

Diferenças Entre A e A'

- **(Alterados)** Bloco formado por linhas/colunas i e j :
 - $A'_{ii} = c^2 A_{ii} - 2sc A_{ij} + s^2 A_{jj}$
 - $A'_{jj} = s^2 A_{ii} + 2sc A_{ij} + c^2 A_{jj}$
 - $A'_{ij} = A'_{ji} = (c^2 - s^2)A_{ij} + sc(A_{ii} - A_{jj})$ (será anulado)
- **Inalterados:** Elementos com índices fora do conjunto $\{i, j\}$.
- **Nas linhas/colunas i e j com outros índices k :**
 - $A'_{ik} = c A_{ik} - s A_{jk}$
 - $A'_{jk} = s A_{ik} + c A_{jk}$
 - Portanto, $(A'_{ik})^2 + (A'_{jk})^2 = A_{ik}^2 + A_{jk}^2$ ("energia" preservada)

Preenchimento (Fill-in)

- **O que ocorre:**
 - Elementos inicialmente nulos em linhas/colunas i ou j podem se tornar não-nulos.
 - Isso ocorre devido às combinações lineares durante a rotação.
- **Impacto:**
 - O "fill-in" local não impede a convergência, pois a norma off-diagonal é reduzida.
 - No entanto, é inviável aplicá-lo em matrizes esparsas de grande escala.

Garantia de Convergência

- **Mesmo com preenchimento:**
 - Cada rotação anula ou diminui significativamente o elemento A_{ij} .
 - A soma dos quadrados dos elementos fora da diagonal (norma off-diagonal) decai a cada iteração.
- **Resultado:**
 - A matriz converge para uma forma diagonal cujos elementos diagonais são os autovalores de A .

Iteração do Quociente de Rayleigh

Passos Principais

- Atualize a estimativa do autovalor via $\rho(x) = \frac{x^T Ax}{x^T x}$.
- Ajuste o shift em cada iteração.

Desempenho

- Convergência cúbica perto de um autovalor real (rápido, mas cada iteração pode ser cara).
- Bom quando você precisa de alta precisão para um autopar.

Método de Lanczos (para simétricas grandes)

Destaques

- Constrói um subespaço de Krylov: $\mathcal{K}_m(A, v) = \{v, Av, A^2v, \dots, A^{m-1}v\}$.
- Produz uma matriz tridiagonal cujos autovalores se aproximam dos de A .

Caso de uso

- Eficiente para matrizes esparsas e grandes.
- Geralmente usado para obter apenas os k autovalores principais.

Método de Arnoldi (não simétricas)

O que é?

- Generaliza Lanczos para matrizes não simétricas (ou não Hermitianas).
- Constrói uma matriz de Hessenberg superior que se aproxima dos autovalores (valores de Ritz).

Caso de uso

- Problemas grandes, esparsos e não simétricos (como matrizes de adjacência de grafos direcionados).

Conclusão

- Métodos da Potência / Rayleigh: abordagens iterativas "atire para o topo".
- QR: robusto para espectro completo, usado em bibliotecas padrão.
- Lanczos / Arnoldi: mantenha barato e aproxime para matrizes grandes.
- Teoria espectral: real simétrico é o melhor cenário. Não simétrico precisa de cautela extra.