

Mínimos Quadrados


Decomposição QR


Conteúdo

1. Introdução ao Problema de Mínimos Quadrados Discreto
2. Método dos Mínimos Quadrados
3. Decomposição QR
4. Processo de Gram-Schmidt
5. Processo de Gram-Schmidt Modificado
6. Refletores de Householder
7. Householder QR

Introdução ao Problema de Mínimos Quadrados Discreto

Dado um conjunto de pontos de dados discretos $\{(t_i, y_i)\}_{i=1}^m$, o objetivo do **problema de mínimos quadrados discreto** é encontrar um polinômio $p(t)$ de grau d que aproxime esses dados minimizando o erro residual.





Formulação Matemática

O polinômio $p(t)$ pode ser expresso como:

$$p(t) = a_0 + a_1t + a_2t^2 + \dots + a_dt^d$$

Os resíduos para cada ponto de dados são:

$$r_i = y_i - p(t_i), \quad \text{para } i = 1, 2, \dots, m$$

O objetivo é minimizar a soma dos quadrados dos resíduos:

$$\min_{a_0, a_1, \dots, a_d} \sum_{i=1}^m (y_i - p(t_i))^2$$

Representação Matricial

Podemos reescrever o problema em termos matriciais como:

$$\mathbf{V}\mathbf{a} \approx \mathbf{y}$$

onde \mathbf{a} é o vetor de coeficientes do polinômio $p(t)$ e \mathbf{V} é a matriz de Vandermonde.

Assim, temos:

$$\underbrace{\begin{bmatrix} 1 & t_1 & t_1^2 & \cdots & t_1^d \\ 1 & t_2 & t_2^2 & \cdots & t_2^d \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & t_m & t_m^2 & \cdots & t_m^d \end{bmatrix}}_{\text{Matriz de Vandermonde}} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_d \end{bmatrix} \approx \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

2. Método dos Mínimos Quadrados

Dado um sistema sobredeterminado $A\mathbf{x} \approx \mathbf{b}$:

- $A \in \mathbb{R}^{m \times n}$, $m \gg n$ (mais equações do que incógnitas)
- Queremos minimizar o erro residual:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2^2$$

A solução é dada pelas **equações normais** [1]:

$$A^\top A\mathbf{x} = A^\top \mathbf{b},$$

que é um sistema linear de n equações e n incógnitas.

[1]: Pode se demonstrar que a solução das equações normais é o ponto de mínimo global do problema de mínimos quadrados.

3. Decomposição QR

Definição

A decomposição QR de uma matriz $A \in \mathbb{R}^{m \times n}$ ($m \geq n$) é a fatoração de A em:

$$A = QR$$

onde:

- $Q \in \mathbb{R}^{m \times m}$ é uma matriz ortogonal ($Q^T Q = I$)
- $R \in \mathbb{R}^{m \times n}$ é uma matriz triangular superior

Aplicação aos Mínimos Quadrados

Substituindo $A = QR$ na equação das mínimas quadrados:

$$QR\mathbf{x} \approx \mathbf{b}$$

Multiplicando ambos os lados por Q^\top :

$$Q^\top QR\mathbf{x} = R\mathbf{x} = Q^\top \mathbf{b}$$

Como R é triangular superior, basta aplicarmos a substituição regressiva para encontrar a solução:

$$\mathbf{x} = R^{-1}Q^\top \mathbf{b}$$

4. Processo de Gram-Schmidt

Seja $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\} \in \mathbb{R}^m$ um conjunto LI. A projeção de \mathbf{v} sobre \mathbf{u} é dada por:

1. Primeiro vetor ortonormal: $\mathbf{q}_1 = \frac{\mathbf{a}_1}{\|\mathbf{a}_1\|_2}$

2. Segundo vetor ortonormal:

$$\mathbf{q}_2 = \frac{\mathbf{a}_2 - \text{proj}_{\mathbf{q}_1}(\mathbf{a}_2)}{\|\mathbf{a}_2 - \text{proj}_{\mathbf{q}_1}(\mathbf{a}_2)\|_2}$$

3. Generalização para o k -ésimo vetor:

$$\mathbf{q}_k = \frac{\mathbf{a}_k - \sum_{j=1}^{k-1} (\mathbf{q}_j^\top \mathbf{a}_k) \mathbf{q}_j}{\|\mathbf{a}_k - \sum_{j=1}^{k-1} (\mathbf{q}_j^\top \mathbf{a}_k) \mathbf{q}_j\|_2}$$

$$\text{proj}_{\mathbf{u}}(\mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}$$

5. Processo de Gram-Schmidt Modificado

Diferença principal:

- No **Gram-Schmidt clássico**, projetamos e subtraímos simultaneamente.
- No **modificado**, projetamos e subtraímos **incrementalmente**, garantindo maior ortogonalidade.

Algoritmo: GS modificado

Para cada vetor $\mathbf{a}_k \in \mathbb{R}^m$:

1. Inicialize $\mathbf{r}_k = \mathbf{a}_k$.
2. Para cada vetor ortonormal anterior

\mathbf{q}_j :

$$r_{jk} = \mathbf{q}_j^\top \mathbf{a}_k, \quad \mathbf{r}_k = \mathbf{r}_k - r_{jk} \mathbf{q}_j$$

3. Normalize:

$$\mathbf{q}_k = \frac{\mathbf{r}_k}{\|\mathbf{r}_k\|_2}$$

6. Refletores de Householder


Definição

Um refletor de Householder é uma matriz ortogonal $H \in \mathbb{R}^{m \times m}$ que reflete um vetor $\mathbf{x} \in \mathbb{R}^m$ em relação a um hiperplano ortogonal a um vetor $\mathbf{v} \in \mathbb{R}^m$:

$$H = I - 2 \frac{\mathbf{v}\mathbf{v}^\top}{\mathbf{v}^\top \mathbf{v}}$$

Propriedades:

- $H^\top H = I$ (ortogonalidade)
- $H = H^\top$ (simetria)



7. Householder QR

As reflexões de Householder podem ser aplicadas na decomposição QR .

O processo envolve a construção iterativa de matrizes de Householder para introduzir zeros abaixo da diagonal principal, transformando A em R .

O produto dessas matrizes de Householder forma a matriz ortogonal Q .

$$\underbrace{H_n H_{n-1} \cdots H_1}_{\text{Matrizes de Householder}} A = R$$

Ideia Central

Suponha que desejamos refletir um vetor $\mathbf{x} \in \mathbb{R}^n$ de modo que ele se alinhe com um múltiplo do primeiro vetor base padrão $\mathbf{e}_1 = [1, 0, 0, \dots, 0]^T$.

1. Calcule a norma de \mathbf{x} :

$$\|\mathbf{x}\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

2. Determine o escalar α :

$$\alpha = -\text{sign}(x_1) \cdot \|\mathbf{x}\|$$

3. Construa o vetor \mathbf{v} :

$$\mathbf{v} = \mathbf{x} - \alpha \mathbf{e}_1$$

4. Normalize \mathbf{v} :

$$\mathbf{v} = \frac{\mathbf{v}}{\|\mathbf{v}\|}$$

- A matriz de Householder resultante é $H = I - 2\mathbf{v}\mathbf{v}^T$.
- $H\mathbf{x}$ é um vetor com zeros em todas as componentes, exceto a primeira.

Ideia Central (continuação)

Para aplicar sucessivamente as reflexões de Householder e reduzir a matriz A a uma forma triangular superior, seguimos o seguinte procedimento:

1. Inicialmente, aplicamos a primeira reflexão de Householder H_1 à matriz completa A , zerando os elementos abaixo do primeiro elemento da primeira coluna. A matriz H_1 é da mesma dimensão de A .

$$H_1 A = \begin{bmatrix} * & * & * \\ 0 & * & * \\ 0 & * & * \end{bmatrix}$$

Ideia Central (continuação)

2. Depois, excluimos a primeira linha e a primeira coluna de A e construímos a matriz de Householder H_2 para zerar os elementos abaixo do primeiro elemento dessa submatriz. Aplicamos

$$\underbrace{\begin{bmatrix} 1 & 0 & 0 \\ 0 & * & * \\ 0 & * & * \end{bmatrix}}_{H_2} H_1 A = \begin{bmatrix} * & * & * \\ 0 & * & * \\ 0 & 0 & * \end{bmatrix}$$

3. Esse processo é repetido sucessivamente para submatrizes menores, até que todos os elementos abaixo da diagonal principal de A sejam zerados.

Exercício:

1. Aplique a decomposição QR utilizando o refletor de Householder à matriz:

$$A = \begin{bmatrix} 4 & 1 & 2 \\ 2 & 3 & 1 \\ 1 & 2 & 3 \end{bmatrix}$$

2. Construa uma matriz de Hilbert 6×6 ;
 - 2.1. Aplique a decomposição QR utilizando (a) o processo de Gram-Schmidt clássico, (b) o processo de Gram-Schmidt modificado e (c) o refletor de Householder;
 - 2.2. Compare a precisão da decomposição QR utilizando os três métodos.

PERGUNTAS?