

Sensibilidade de Sistemas Lineares

Efeitos dos Erros de Arredondamento

Errar não é só humano




Fig. 1.6. Types of errors in a computational process

1. Erro do Modelo (e_m)

Ocorre ao simplificar a realidade física (PP) em um modelo matemático (MP). Está além do controle computacional.

Errar não é só humano




Fig. 1.6. Types of errors in a computational process

2. Erro Algorítmico (e_a)

Erros introduzidos durante a resolução computacional do modelo matemático, principalmente devido a arredondamentos na representação numérica.

Errar não é só humano

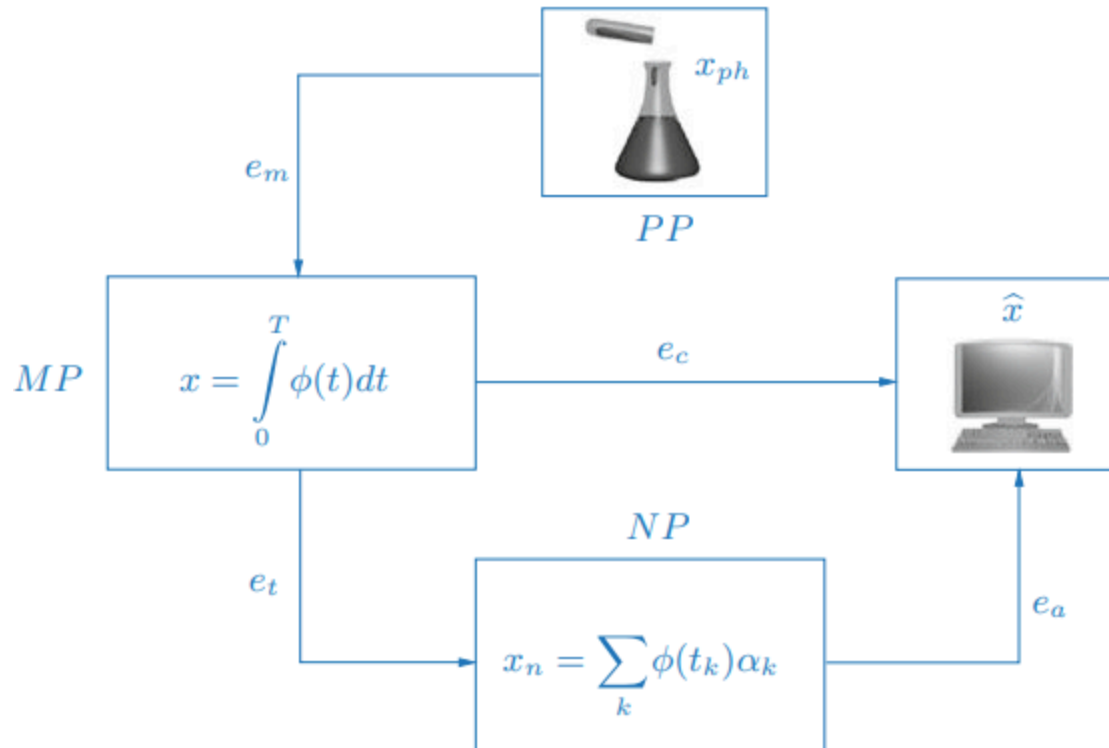


Fig. 1.6. Types of errors in a computational process

3. Erro de Truncamento (e_t)

Erros introduzidos ao aproximar sequências infinitas por operações finitas. Ocorre quando a solução numérica (x_n) difere da solução exata (x).

Errar não é só humano




Fig. 1.6. Types of errors in a computational process

4. Erro Computacional (e_c)

O erro total que surge a partir da soma do erro algorítmico (e_a) e do erro de truncamento (e_t).

Este é o erro de interesse ao resolver problemas numéricos.

Caso de estudo

Para a matriz A , calcule a solução dos sistemas lineares $Ax = b$ e $A\hat{x} = \hat{b}$ onde

$$A = \begin{bmatrix} 1000 & 999 \\ 999 & 998 \end{bmatrix}, \quad b = \begin{bmatrix} 1999 \\ 1998 \end{bmatrix} \quad \text{e} \quad \hat{b} = \begin{bmatrix} 1999 \\ 1998.001 \end{bmatrix}.$$

Escrevendo $\hat{x} = x + \delta x$ e $\hat{b} = b + \delta b$, compare as variações relativas $\frac{\delta x}{x}$ e $\frac{\delta b}{b}$.

Norma de um vetor

Uma **norma** (ou **norma vetorial**) em \mathbb{R}^n é uma função que atribui a cada $x \in \mathbb{R}^n$ um número real não-negativo $\|x\|$, tal que para todos $x, y \in \mathbb{R}^n$ e todos $\alpha \in \mathbb{R}$:

1. Positividade

$$\|x\| \geq 0 \text{ para todo } x, \text{ e } \|x\| = 0 \text{ se e somente se } x = 0$$

2. Homogeneidade absoluta

$$\|\alpha x\| = |\alpha| \|x\|$$

3. Desigualdade triangular

$$\|x + y\| \leq \|x\| + \|y\|$$

Exemplos

1. Norma euclidiana

$$||x||_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

2. Norma de Manhattan (ou *norma do valor absoluto* ou *norma 1*)

$$||x||_1 = |x_1| + |x_2| + \cdots + |x_n|$$

3. Norma infinita

$$||x||_\infty = \max(|x_1|, |x_2|, \cdots, |x_n|)$$

4. Norma p

$$||x||_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

Norma de uma matriz

Para todos $A, B \in \mathbb{R}^{n \times n}$ e $\alpha \in \mathbb{R}$:

1. Positividade

$\|A\| \geq 0$ para todo A , e $\|A\| = 0$ se e somente se $A = 0$

2. Homogeneidade absoluta

$$\|A\alpha\| = |\alpha| \|A\|$$

3. Desigualdade triangular

$$\|A + B\| \leq \|A\| + \|B\|$$

4. Submultiplicatividade

$$\|AB\| \leq \|A\| \|B\|$$

Exemplos

1. Norma de Frobenius

$$||A||_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}$$

2. Norma de Schatten p

$$||A||_p = \left(\sum_{i=1}^n \sigma_i^p \right)^{1/p},$$

onde σ_i são os valores singulares de A .

Norma Matricial Induzida

Seja $A \in \mathbb{R}^{n \times n}$. A norma induzida por uma norma vetorial $\|\cdot\|$ é definida como

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

A norma induzida mede a amplificação máxima de um vetor x por uma matriz A .

Teorema 2.1.26

A norma matricial induzida é uma norma matricial.

Teorema 2.1.24

Uma norma vetorial e sua norma matricial induzida satisfazem a desigualdade

$$||Ax|| \leq ||A|| ||x||$$

para todo $A \in \mathbb{R}^{n \times n}$ e $x \in \mathbb{R}^n$.

Além disso, sempre existe um vetor x tal que $||Ax|| = ||A|| ||x||$.

Retornando ao caso de estudo

1. $Ax = b$ e $A(x + \delta x) = b + \delta b$ implica em $A\delta x = \delta b$, portanto $\delta x = A^{-1}\delta b$.
2. $Ax = b$ implica em $x = A^{-1}b$.
3. Sabendo que $\|Az\| \leq \|A\|\|z\|$ para todo $z \in \mathbb{R}^n$, temos

$$\|A^{-1}\delta b\| \leq \|A^{-1}\|\|\delta b\| \quad \text{e} \quad \|A^{-1}b\| \leq \|A^{-1}\|\|b\|.$$

Portanto,

$$\frac{\|\delta x\|}{\|x\|} \leq \|A\|\|A^{-1}\| \frac{\|\delta b\|}{\|b\|}.$$

Número de Condição

Seja A uma matriz não singular. O número de condição de A é definido como

$$\kappa(A) = \|A\| \|A^{-1}\|.$$

1. *O número de condição mede a sensibilidade da solução de um sistema linear às variações dos dados.*
2. *Em um sistema linear com número de condição alto, pequenas variações nos dados podem causar grandes variações na solução.*

Retornando ao caso de estudo

Calcule o número de condição da matriz A para as normas de Frobenius.

Exemplo: Matrizes de Hilbert

Os exemplos mais famosos de matrizes mal condicionadas são as **matrizes de Hilbert**, definidas por $h_{ij} = 1/(i + j - 1)$.

Essas matrizes são simétricas, podem ser mostradas como positivas definidas e se tornam cada vez mais mal condicionadas à medida que n aumenta. Por exemplo, $\kappa_2(H_4) \approx 1.6 \times 10^4$ e $\kappa_2(H_8) \approx 1.5 \times 10^{10}$.

$$H_4 = \begin{bmatrix} 1 & 1/2 & 1/3 & 1/4 \\ 1/2 & 1/3 & 1/4 & 1/5 \\ 1/3 & 1/4 & 1/5 & 1/6 \\ 1/4 & 1/5 & 1/6 & 1/7 \end{bmatrix},$$

PERGUNTAS?