

# Decomposição em Valores Singulares

*Singular Value Decomposition (SVD)*

## Construção de uma base ortonormal

Suponha que você tenha um conjunto


$V = \{v_1, \dots, v_n\}$  de vetores independentes em um espaço vetorial de dimensão  $m$ , com  $n \leq m$ .

Você quer construir um conjunto  $U = \{u_1, \dots, u_n\}$  ortogonal tal que


$$\text{span}(U) = \text{span}(V).$$


Podemos utilizar Gram-Schmidt, mas ele é muito ruim devido à acumulação de erros de arredondamento.

A maneira correta de resolver este problema é pela SVD.



Uma **matriz não singular**  $A_{n \times n}$  mapeia um espaço vetorial em outro de mesma dimensão. O vetor  $x$  é mapeado em  $b$ , de forma que  $x$  satisfaz a equação  $Ax = b$ .





Uma **matriz singular**  $A$  mapeia um espaço vetorial em outro de dimensão menor. Aqui, o plano é mapeado em uma linha.

## Range (Imagem)

Seja  $A$  uma matriz  $m \times n$ . O **range** de  $A$  é o conjunto de todos os vetores  $b$  que podem ser escritos como  $Ax$  para algum  $x \in \mathbb{R}^n$ .

## Null Space (Núcleo)

Seja  $A$  uma matriz  $m \times n$ . O **null space** de  $A$  é o conjunto de todos os vetores  $x \in \mathbb{R}^n$  tais que  $Ax = 0$ .

## Rank (Posto)

O **rank** de  $A$  é o número de linhas (ou colunas) linearmente independentes de  $A$ .

### Teorema 4.1.1 (SVD)

Seja  $A$  uma matriz não-nula  $m \times n$  com rank (posto)  $r$ . Então,  $A$  pode ser expressa como um produto de três matrizes:

$$A = U\Sigma V^T,$$

onde  $U \in \mathbb{R}^{m \times m}$  e  $V \in \mathbb{R}^{n \times n}$  são matrizes ortogonais, e  $\Sigma \in \mathbb{R}^{m \times n}$  é uma matriz diagonal com entradas não-negativas.

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & & \\ & \sigma_2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r & & \\ & & & & 0 & \\ & & & & & \ddots \end{bmatrix},$$

com  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$

## Significado da SVD

Uma matriz  $A \in \mathbb{R}^{m \times n}$  mapeia vetores  $x \in \mathbb{R}^n$  em vetores  $Ax \in \mathbb{R}^m$ .

O Teorema 4.1.1 afirma que existe uma base ortonormal  $\{v_1, \dots, v_n\}$  de  $\mathbb{R}^n$  e uma base ortonormal  $\{u_1, \dots, u_m\}$  de  $\mathbb{R}^m$  tais que

$$Av_i = \sigma_i u_i, \quad i = 1, \dots, r,$$

com  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ .

Os escalares (números)  $\sigma_i$  são os **valores singulares** de  $A$  e os vetores  $u_i$  e  $v_i$  são os **vetores singulares** de  $A$ .

Geometricamente, o teorema afirma que qualquer matriz  $A$  pode ser decomposta em uma rotação seguida de uma dilatação (scaling) seguida de outra rotação.

## Consequências SVD

Seja  $AV = U\Sigma$  a SVD de  $A$ . Então,

$$\text{range}(A) = \text{span}\{u_1, \dots, u_r\}$$

$$\text{null}(A) = \text{span}\{v_{r+1}, \dots, v_n\}$$


$$\text{range}(A^T) = \text{span}\{v_1, \dots, v_r\}$$

$$\text{null}(A^T) = \text{span}\{u_{r+1}, \dots, u_m\}$$

## Teorema: Núcleo e Imagem

Seja  $A$  uma matriz  $m \times n$ . Então,

$$\dim(\text{range}(A)) + \dim(\text{null}(A)) = n.$$





## Relação entre SVD e Autovalores de $A^T A$

Se  $A = U\Sigma V^T$  é a SVD de  $A \in \mathbb{R}^{m \times n}$ , então

$$\begin{aligned} A^T A &= (V\Sigma^T U^T)U\Sigma V^T \\ &= V\Sigma^T \Sigma V^T \end{aligned}$$

E, portanto,

$$A^T A V = V\Sigma^T \Sigma = V \text{diag}(\sigma^2),$$

onde  $\text{diag}(\sigma^2)$  é a matriz diagonal com os quadrados dos valores singulares de  $A$

.

Sendo assim, os autovalores de  $A^T A$  são os quadrados dos valores singulares de  $A$ .

# Algoritmo SVD

Um algoritmo ingênuo para calcular a SVD é reduzir o problema a um problema de autovalores da matriz simétrica  $A^T A$ .

Esta abordagem é simples, mas não é numericamente eficiente nem estável.

```
def naive_svd(A):  
    ATA = A.T * A  
    # autovalores (decresc.) ordenados  
    D2, V = naive_eigenvalues(ATA)  
    D = np.sqrt(D2)  
    UD = A * V  
    U = UD * inv(D)  
    return U, D, V.T
```

## Aplicações e Exercícios

1. Calcule a SVD da matriz  $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$ .
2. Uma matriz retangular  $A \in \mathbb{R}^{m \times n}$  não tem inversa, mas podemos construir a sua pseudo-inversa  $A^+ = V\Sigma^+U^T$ , onde  $\Sigma^+$  é a matriz diagonal com os inversos dos valores singulares não-nulos de  $A$ . Calcule a pseudo-inversa de  $A$  e veja se ela é uma boa aproximação de inversa de  $A$ .
3. Escolha uma imagem e obtenha sua representação matricial  $A \in \mathbb{R}^{m \times n}$ . Depois, calcule a SVD de  $A$  e, finalmente, exclua os menores valores singulares e reconstrua a imagem reduzida.

**PERGUNTAS?**