

Decomposição em Valores Singulares

Singular Value Decomposition (SVD)

Construção de uma base ortonormal

Suponha que você tenha um conjunto


$V = \{v_1, \dots, v_n\}$ de vetores independentes em um espaço vetorial de dimensão m , com $n \leq m$.

Você quer construir um conjunto $U = \{u_1, \dots, u_n\}$ ortogonal tal que


$$\text{span}(U) = \text{span}(V).$$


Podemos utilizar Gram-Schmidt, mas ele é muito ruim devido à acumulação de erros de arredondamento.

A maneira correta de resolver este problema é pela SVD.



Uma **matriz não singular** $A_{n \times n}$ mapeia um espaço vetorial em outro de mesma dimensão. O vetor x é mapeado em b , de forma que x satisfaz a equação $Ax = b$.





Uma **matriz singular** A mapeia um espaço vetorial em outro de dimensão menor. Aqui, o plano é mapeado em uma linha.

Range (Imagem)

Seja A uma matriz $m \times n$. O **range** de A é o conjunto de todos os vetores b que podem ser escritos como Ax para algum $x \in \mathbb{R}^n$.

Null Space (Núcleo)

Seja A uma matriz $m \times n$. O **null space** de A é o conjunto de todos os vetores $x \in \mathbb{R}^n$ tais que $Ax = 0$.

Rank (Posto)

O **rank** de A é o número de linhas (ou colunas) linearmente independentes de A .

Teorema 4.1.1 (SVD)

Seja A uma matriz não-nula $m \times n$ com rank (posto) r . Então, A pode ser expressa como um produto de três matrizes:

$$A = U\Sigma V^T,$$

onde $U \in \mathbb{R}^{m \times m}$ e $V \in \mathbb{R}^{n \times n}$ são matrizes ortogonais, e $\Sigma \in \mathbb{R}^{m \times n}$ é uma matriz diagonal com entradas não-negativas.

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & & \\ & \sigma_2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r & & \\ & & & & 0 & \\ & & & & & \ddots \end{bmatrix},$$

com $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$

Significado da SVD

Uma matriz $A \in \mathbb{R}^{m \times n}$ mapeia vetores $x \in \mathbb{R}^n$ em vetores $Ax \in \mathbb{R}^m$.

O Teorema 4.1.1 afirma que existe uma base ortonormal $\{v_1, \dots, v_n\}$ de \mathbb{R}^n e uma base ortonormal $\{u_1, \dots, u_m\}$ de \mathbb{R}^m tais que

$$Av_i = \sigma_i u_i, \quad i = 1, \dots, r,$$

com $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$.

Os escalares (números) σ_i são os **valores singulares** de A e os vetores u_i e v_i são os **vetores singulares** de A .

Geometricamente, o teorema afirma que qualquer matriz A pode ser decomposta em uma rotação seguida de uma dilatação (scaling) seguida de outra rotação.

Consequências SVD

Seja $AV = U\Sigma$ a SVD de A . Então,

$$\text{range}(A) = \text{span}\{u_1, \dots, u_r\}$$

$$\text{null}(A) = \text{span}\{v_{r+1}, \dots, v_n\}$$


$$\text{range}(A^T) = \text{span}\{v_1, \dots, v_r\}$$

$$\text{null}(A^T) = \text{span}\{u_{r+1}, \dots, u_m\}$$

Teorema: Núcleo e Imagem

Seja A uma matriz $m \times n$. Então,

$$\dim(\text{range}(A)) + \dim(\text{null}(A)) = n.$$



Relação entre SVD e Autovalores de $A^T A$

Se $A = U\Sigma V^T$ é a SVD de $A \in \mathbb{R}^{m \times n}$, então

$$\begin{aligned} A^T A &= (V\Sigma^T U^T)U\Sigma V^T \\ &= V\Sigma^T \Sigma V^T \end{aligned}$$

E, portanto, $A^T A V = V\Sigma^T \Sigma = V \text{diag}(\sigma^2)$, onde $\text{diag}(\sigma^2)$ é a matriz diagonal com os quadrados dos valores singulares de A .

Logo, os autovalores de $A^T A$ são os quadrados dos valores singulares de A .

Algoritmo (Ingênuo) para SVD

Um algoritmo ingênuo para calcular a SVD é reduzir o problema a um problema de autovalores da matriz simétrica $A^T A$.

Esta abordagem é simples, mas não é numericamente eficiente nem estável.

```
def naive_svd(A):  
    ATA = A.T * A  
    # autovalores (decresc.) ordenados  
    D2, V = naive_eigenvalues(ATA)  
    D = np.sqrt(D2)  
    UD = A * V  
    U = UD * inv(D)  
    return U, D, V.T
```

Aplicações e Exercícios

1. Calcule a SVD da matriz $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$.
2. Uma matriz retangular $A \in \mathbb{R}^{m \times n}$ não tem inversa, mas podemos construir a sua pseudo-inversa $A^+ = V\Sigma^+U^T$, onde Σ^+ é a matriz diagonal com os inversos dos valores singulares não-nulos de A . Calcule a pseudo-inversa de A e veja se ela é uma boa aproximação de inversa de A .
3. Escolha uma imagem e obtenha sua representação matricial $A \in \mathbb{R}^{m \times n}$. Depois, calcule a SVD de A e, finalmente, exclua os menores valores singulares e reconstrua a imagem reduzida.

PERGUNTAS?